

Análisis del comportamiento del Índice de Desarrollo Humano (IDH) y sus factores sociodemográficos determinantes en las regiones con mayor rezago en Colombia a nivel departamental entre 2011 y 2022

Miguel Augusto Gómez Delgado & Alejandro Rivera Muriel

Bootcamp de análisis de datos explorador de Talento Tech

Medellín, Junio 2026

Índice

1. Introducción

- 1.1 Objetivo general
- 1.2 Objetivos específicos
- 1.3 Planteamiento del problema
- 1.4 Datos Utilizados

2. Desarrollo Del Proyecto

- 2.1 Integración de Google Drive en el Entorno de Ejecución de Google Colab
- 2.2 Importación de Librerías y Carga de Datos
- 2.3 Carga de la Base de Datos
- 2.4 Exploración e Imputación de Datos
- 2.5 Análisis de los Datos
 - Tendencia Histórica del IDH en Colombia
 - Brecha de Desarrollo Humano en Colombia (Top 5 vs. Bottom 5)
 - Promedio Histórico (2011-2022) de las Dimensiones del IDH (Bottom 5)
 - Tasas de Matriculación y Deserción de los departamentos rezagados
 - Retención Educativa por Edad y Factores Sociodemográficos

3. Conclusiones

4. Recomendaciones

5. Limitaciones de la investigación

6. Referencias

1. Introducción

El Índice de Desarrollo Humano (IDH) mide la calidad de vida evaluando tres dimensiones: Salud, Ingresos y Educación. Aunque el promedio de Colombia muestra mejoras, la cifra nacional oculta la gran brecha existente entre las capitales y la periferia, especialmente en departamentos como Chocó, Guainía, La Guajira, Vaupés y Vichada. Este documento analiza los datos del IDH subnacional para identificar cuál de estas dimensiones frena el avance de las regiones más vulnerables. A partir de ahí, la investigación se enfoca en el comportamiento de las aulas en estos cinco departamentos entre 2011 y 2022.

1.1 Objetivo general

Analizar el comportamiento del Índice de Desarrollo Humano (IDH) y sus factores sociodemográficos determinantes en las regiones con mayor rezago en Colombia a nivel departamental entre 2011 y 2022.

1.2 Objetivos específicos

- Estructurar y limpiar conjuntos de datos sociodemográficos y del IDH a nivel departamental para el periodo 2011-2022, unificando múltiples fuentes gubernamentales.
- Segmentar los departamentos de Colombia según su evolución histórica del IDH para identificar el clúster con la mayor brecha de desarrollo.
- Descomponer el IDH de las regiones rezagadas para aislar estadísticamente la dimensión con el rendimiento más crítico.
- Evaluar la correlación entre la dimensión más afectada (Educación) y variables sociodemográficas estructurales (acceso a internet, pobreza extrema, ruralidad).
- Formular recomendaciones estratégicas y planes de acción focalizados para mitigar las brechas identificadas en la población más vulnerable.

1.3 Planteamiento del problema

Aunque Colombia ha registrado una tendencia de mejora en su Índice de Desarrollo Humano (IDH) a nivel nacional durante la última década, este crecimiento oculta profundas brechas territoriales. En departamentos periféricos como el Amazonas, el IDH no solo evidencia un rezago frente al promedio nacional, sino que en algunos casos ha presentado retrocesos recientes. Esta divergencia perpetúa ciclos de pobreza y limita la calidad de vida. Existe la necesidad de aislar de manera cuantitativa qué dimensiones específicas (Salud, Educación o Ingreso) están arrastrando el indicador hacia abajo y correlacionar estas caídas con factores sociodemográficos locales. Sin este análisis de causa raíz basado en datos, las políticas de intervención seguirán siendo ineficientes y generalistas, en lugar de estar focalizadas en las vulnerabilidades reales de cada departamento.

1.4 Datos Utilizados


Los datos han sido recolectado por medio de diferentes plataformas oficiales que miden el índice de desarrollo humano así como distintos indicadores socioeconómicos pertinentes a

este índice (salud, educación, economía). Los datos empleados para la medición del índice a nivel nacional y departamental del índice de desarrollo humano fueron extraídos del dataset público elaborado por el Programa de la Naciones Unidas para el Desarrollo (UNDP). Para los datos relativos a la educación para los departamentos evaluados, los datos se obtuvieron del sistema de datos abiertos del Ministerio de Educación Nacional (MEN). Los datos usados fueron específicamente los datos de matriculación en Educación Preescolar Básica y Media de Colombia, del año 2010 al 2022, Los datos de deserción estudiantil en Educación Preescolar Básica y Media de Colombia en desde 2010 a 2022.

2. Desarrollo Del Proyecto

2.1 Integración de Google Drive en el Entorno de Ejecución de Google Colab

Se integra a Google Drive dentro de la ejecución de Google Collaboratory (Colab). Esta conexión permite el acceso directo y la manipulación de archivos y directorios almacenados en la cuenta con los datasets de Google Drive, optimizando los flujos de trabajo de análisis de datos.



2.2 Importación de Librerías y Carga de Datos

Es importante importar estas librerías porque:

- Pandas: Facilita la manipulación y análisis de datos tabulares, permitiendo realizar filtros, agregaciones y limpieza de datos de forma eficiente.
- NumPy: Permite realizar operaciones matemáticas avanzadas, manejo de arrays y funciones de estadística clave para el análisis de datos.
- Matplotlib: Es una biblioteca clave para crear visualizaciones básicas como histogramas, gráficos de barras y dispersión.
- Seaborn: Permite crear visualizaciones más avanzadas, atractivas y que faciliten el reconocimiento de patrones complejos.

Importación de librerías para tratamiento y limpieza de datos

```
1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 import seaborn as sns
```

2.3 Carga de la Base de Datos

En este paso realizamos la carga de la base de datos directamente desde Google Drive o el entorno de Colab. Esto es fundamental porque:

- Ruta del archivo: Especificamos la ubicación del archivo en Drive para que Colab pueda acceder a él.
- Lectura del archivo: Utilizamos la función `pd.read_excel()` de la biblioteca Pandas, que permite leer archivos en formato Excel de manera eficiente.
- Creación del DataFrame: Al almacenar el contenido del archivo en la variable `df`, obtenemos una estructura tabular que facilita la manipulación y análisis de los datos en las siguientes etapas.

Carga de datos del dataset de Índice de desarrollo Humano a nivel subnacional:

```
10 # Leer mi documento
11 df = pd.read_excel('/content/drive/MyDrive/idhcolsubnacional/idhsubnacionalcol2011-2022.xlsx')
```

Carga de datos del dataset de estadísticas en educación preescolar, primaria y media a nivel subnacional:

```
10 # Leer mi documento
11 matricula_departamento_df = pd.read_csv('/content/drive/MyDrive/idhcolsubnacional/MEN_ESTADISTICAS_EN_EDUCACION_EN_PREESCOLAR, BÁSICA Y MEDIA POR DEPARTAMENTO_20260515.csv')
```

Carga de datos del dataset de matriculación en educación preescolar, primaria y media a nivel subnacional:

```
10 # Leer mi documento
11 matricula_b5_df = pd.read_csv('/content/drive/MyDrive/idhcolsubnacional/matriculacion_bottom5.csv')
```

2.4 Exploración e Imputación de Datos

Información sobre dataframe de Índice desarrollo humano:

No hay datos nulos presentes en el dataframe, los formatos de las columnas son los adecuados por lo que no se procede a hacer ninguna imputación ni normalización de datos.

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 408 entries, 0 to 407
Data columns (total 11 columns):
#   Column                                                                 Non-Null Count  Dtype
---  -
0   departamento                                                            408 non-null   object
1   índice_de_desarrollo_humano                                             408 non-null   float64
2   grupo_de_idh                                                            408 non-null   object
3   año                                                                    408 non-null   int64
4   índice_estandarizado_de_esperanza_de_vida                             408 non-null   float64
5   años_promedio_de_educación_estandarizados                             408 non-null   float64
6   índice_estandarizado_de_pib_per_cápita_minero_ppa                     408 non-null   float64
7   esperanza_de_vida_al_nacer                                              408 non-null   float64
8   años_esperados_de_escolaridad                                           408 non-null   float64
9   años_promedio_de_educación                                              408 non-null   float64
10  pib_per_cápita_(ppa)                                                    408 non-null   object
dtypes: float64(7), int64(1), object(3)
memory usage: 35.2+ KB
None

```

Información sobre dataframe de Índice Matriculación en educación preescolar, primaria y media a nivel subnacional :

Se procedió a la eliminación de columnas prescindibles así como la imputación y normalización de datos. Las columnas relacionadas con el establecimiento o sede de la matriculación son eliminadas pues estas no son pertinentes para el análisis macro que se plantea. Las columnas relativas a la secretaría se eliminan asimismo puesto que estos datos contienen la misma información en relación al departamento o municipio siendo redundante. Finalmente, la información relativa a los detalles de la institución es también eliminada pues el enfoque del análisis no contempla los aspectos técnicos de impartición de la educación (calendario, jornada, metodología, carácter, especialidad). Una vez depuradas las columnas el dataframe no presenta datos nulos y el formato de los datos es el adecuado por lo que no se requiere de más limpieza de datos.

Valores nulos por columna dataframe de Matriculación

```

Recuento de valores nulos
ANNO_INF                0
COD_DANE_DEPARTAMENTO    0
DEPARTAMENTO             0
COD_SECRETARIA          0
SECRETARIA              0
COD_DANE_MUNICIPIO      0
MUNICIPIO               0
CODIGO_DANE             0
NOMBRE_ESTABLECIMIENTO  5114
COD_SECTOR              0
SECTOR                  0
COD_CALEDARIO           3063
CALEDARIO               3063
CODIGO_DANE_SEDE        0
NOMBRE_SEDE             42932
COD_ZONA                0
ZONA                    0
COD_TIPO_JORNADA        0
TIPO_JORNADA            0
COD_GRADO               0
GRADO                   0
COD_METODOLOGIA         0
METODOLOGIA            698
COD_CARACTER            3063
CARACTER                3063
COD_ESPECIALIDAD        3063
ESPECIALIDAD           3063
EDAD                    0
COD_GENERO              0
GENERO                  0
COD_GRUPO_ETNICO        0
GRUPO_ETNICO            0
COD_SECTOR_CONPES       0
SECTOR_CONPES           0
TOTAL_MATRICULA         0
dtype: int64

```

Columnas a permanecer en el dataframe de Matriculación

```

- Información general de los datos

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2002111 entries, 0 to 2002110
Data columns (total 14 columns):
#   Column                Dtype
---  -
0   anno_inf              int64
1   cod_dane_departamento int64
2   departamento          object
3   cod_dane_municipio    int64
4   municipio             object
5   cod_zona              int64
6   zona                 object
7   cod_grado             int64
8   grado                object
9   edad                 int64
10  cod_genero            object
11  genero                object
12  cod_grupo_etnico      int64
13  grupo_etnico          object
dtypes: int64(7), object(7)
memory usage: 213.8+ MB
None

```

Valores nulos por columna dataframe de Matriculación

```

Recuento de valores nulos
anno_inf          0
cod_dane_departamento 0
departamento     0
cod_dane_municipio 0
municipio         0
cod_zona          0
zona             0
cod_grado         0
grado            0
edad             0
cod_genero        0
genero           0
cod_grupo_etnico  0
grupo_etnico     0

```

Información sobre dataframe de Estadísticas en educación preescolar, primaria y media a nivel subnacional :

Los datos presentados en este dataframe corresponden a datos porcentuales relativos a indicadores en educación (cobertura estudiantil, deserción estudiantil, aprobación, reprobación y repitencia estudiantil), no obstante debido al formato decimal numérico en lugar de punto así como al símbolo de porcentaje en el dato Pandas interpreta el dato de tipo texto o string impidiendo así hacer uso matemático de la información. Debido a esto se reemplazan los datos

de las columnas eliminando el símbolo porcentual, cambiando el símbolo decimal, convirtiendo el tipo de dato a número decimal (float64) y transformando el dato a la escala proporcional de 0 a 1 para que represente precisamente el porcentaje.

Data columns (total 37 columns):				
#	Column	Non-Null Count	Dtype	
---	-----	-----	-----	
0	AÑO	462 non-null	int64	
1	CÓDIGO_DEPARTAMENTO	462 non-null	int64	
2	DEPARTAMENTO	462 non-null	object	
3	POBLACIÓN_5_16	462 non-null	int64	
4	TASA_MATRICULACIÓN_5_16	462 non-null	object	
5	COBERTURA_NETA	462 non-null	object	
6	COBERTURA_NETA_TRANSICIÓN	462 non-null	object	
7	COBERTURA_NETA_PRIMARIA	462 non-null	object	
8	COBERTURA_NETA_SECUNDARIA	462 non-null	object	
9	COBERTURA_NETA_MEDIA	462 non-null	object	
10	COBERTURA_BRUTA	462 non-null	object	
11	COBERTURA_BRUTA_TRANSICIÓN	462 non-null	object	
12	COBERTURA_BRUTA_PRIMARIA	462 non-null	object	
13	COBERTURA_BRUTA_SECUNDARIA	462 non-null	object	
14	COBERTURA_BRUTA_MEDIA	462 non-null	object	
15	TAMAÑO_PROMEDIO_DE_GRUPO	231 non-null	object	
16	SEDES_CONECTADAS_A_INTERNET	231 non-null	float64	
17	DESERCIÓN	462 non-null	object	
18	DESERCIÓN_TRANSICIÓN	461 non-null	object	
19	DESERCIÓN_PRIMARIA	462 non-null	object	
20	DESERCIÓN_SECUNDARIA	462 non-null	object	
21	DESERCIÓN_MEDIA	462 non-null	object	
22	APROBACIÓN	462 non-null	object	
23	APROBACIÓN_TRANSICIÓN	462 non-null	object	
24	APROBACIÓN_PRIMARIA	462 non-null	object	
25	APROBACIÓN_SECUNDARIA	462 non-null	object	
26	APROBACIÓN_MEDIA	462 non-null	object	
27	REPROBACIÓN	462 non-null	object	
28	REPROBACIÓN_TRANSICIÓN	462 non-null	object	
29	REPROBACIÓN_PRIMARIA	462 non-null	object	
30	REPROBACIÓN_SECUNDARIA	462 non-null	object	
31	REPROBACIÓN_MEDIA	462 non-null	object	
32	REPITENCIA	462 non-null	object	
33	REPITENCIA_TRANSICIÓN	462 non-null	object	
34	REPITENCIA_PRIMARIA	462 non-null	object	
35	REPITENCIA_SECUNDARIA	462 non-null	object	
36	REPITENCIA_MEDIA	462 non-null	object	

```

40 #Normalizacion de datos
41 # arreglo de valores numericos de proporcion en string a datos flotantes para las columnas de tasas y proporciones
42 for columns in matricula_departamento_df.columns:
43     if matricula_departamento_df[columns].dtype == 'object':
44         if matricula_departamento_df[columns].str.contains('%', regex=False).any():
45             matricula_departamento_df[columns] = matricula_departamento_df[columns].str.replace('%', '').str.replace(',', '.').astype(float) / 100.0
46
47 # Cambio de str a valor numerico a la columna "TAMAÑO_PROMEDIO_DE_GRUPO"
48 matricula_departamento_df['tamaño_promedio_de_grupo'] = matricula_departamento_df['tamaño_promedio_de_grupo'].str.replace(',', '.').astype(float)

```

```

Recuento de valores nulos
AÑO 0
CÓDIGO_DEPARTAMENTO 0
DEPARTAMENTO 0
POBLACIÓN_5_16 0
TASA_MATRICULACIÓN_5_16 0
COBERTURA_NETA 0
COBERTURA_NETA_TRANSICIÓN 0
COBERTURA_NETA_PRIMARIA 0
COBERTURA_NETA_SECUNDARIA 0
COBERTURA_NETA_MEDIA 0
COBERTURA_BRUTA 0
COBERTURA_BRUTA_TRANSICIÓN 0
COBERTURA_BRUTA_PRIMARIA 0
COBERTURA_BRUTA_SECUNDARIA 0
COBERTURA_BRUTA_MEDIA 0
TAMAÑO_PROMEDIO_DE_GRUPO 231
SEDES_CONECTADAS_A_INTERNET 231
DESERCIÓN 0
DESERCIÓN_TRANSICIÓN 1
DESERCIÓN_PRIMARIA 0
DESERCIÓN_SECUNDARIA 0
DESERCIÓN_MEDIA 0
APROBACIÓN 0
APROBACIÓN_TRANSICIÓN 0
APROBACIÓN_PRIMARIA 0
APROBACIÓN_SECUNDARIA 0
APROBACIÓN_MEDIA 0
REPROBACIÓN 0
REPROBACIÓN_TRANSICIÓN 0
REPROBACIÓN_PRIMARIA 0
REPROBACIÓN_SECUNDARIA 0
REPROBACIÓN_MEDIA 0
REPITENCIA 0
REPITENCIA_TRANSICIÓN 0
REPITENCIA_PRIMARIA 0
REPITENCIA_SECUNDARIA 0
REPITENCIA_MEDIA 0

```

Justificación de reemplazo de datos faltantes para tamaño promedio del grupo por la interpolación de los números contiguos al dato faltante: dado que la columna de tamaño promedio de grupo quiere mostrar el tamaño promedio de las clases, y que este va cambiando a lo largo de los años, usar la interpolación de los datos permite obtener un dato

estimado que no deforma las proyecciones ni tendencias que expresan los datos que sí están presentes. Hacer uso de datos como el promedio podría mostrar saltos abruptos entre años.

```
53 #Imputacion de datos
54 #imputacion de datos faltantes en tamaño promedio de grupo
55 # Se usará el promedio del departamento para los datos faltantes y así evitar
56 matricula_departamento_df = matricula_departamento_df.sort_values(by=['código_departamento', 'año'])
57 matricula_departamento_df['tamaño_promedio_de_grupo'] = matricula_departamento_df['tamaño_promedio_de_grupo'].fillna(
58     matricula_departamento_df.groupby('código_departamento')['tamaño_promedio_de_grupo'].transform(lambda x: x.interpolate(method='linear'))
59 )
```

Justificación de reemplazo de datos faltantes para sedes con acceso a internet con el dato del año anterior: Este dato busca mostrar las sedes educativas con acceso a internet, dado que expresa una realidad de infraestructura, mostrar el promedio de este datos podría alterar drásticamente las proyecciones y tendencias. Dado que es un tema de infraestructura el cual toma tiempo de desarrollarse usando el dato anterior muestra un estimado probable dada la diferencia de tiempo entre un dato y el siguiente.


```
61 #Imputacion de datos faltantes en acceso a internet
62 matricula_departamento_df['sedes_conectadas_a_internet'] = (
63     matricula_departamento_df.groupby('código_departamento')['sedes_conectadas_a_internet']
64     .ffill() # Llena hacia adelante
65     .bfill() # Llena hacia atrás (por si el nulo está en el primer año, 2011)
66 )
```

Justificación de reemplazo de datos faltantes para deserción transición: Este dato como el del tamaño promedio del grupo también muestra una tendencia a lo largo del tiempo y modificarlo por el promedio del grupo de datos mostrará saltos en el tiempo que alteran su tendencia. Es por esto que se procede a imputar el dato por la interpolación numérica del dato faltante según su evolución en los años.

```
68 #Imputacion de datos faltantes en desercion transición
69 matricula_departamento_df['deserción_transición'] = matricula_departamento_df.groupby('código_departamento')['deserción_transición'].transform(
70     lambda x: x.interpolate(method='linear')
71 )
```

2.5 Análisis de los Datos

Tendencia Histórica del IDH en Colombia



Objetivo:

Este gráfico busca exponer la trayectoria histórica del IDH general de Colombia a nivel agregado durante el periodo de estudio (2011-2022). Esto permite establecer la línea base o benchmark del rendimiento del país para determinar la velocidad real del desarrollo social y económico nacional.

Justificación del Gráfico:

Se emplea un gráfico de líneas de series temporales con marcadores puntuales y etiquetas de datos explícitas con tres decimales (estándar internacional del PNUD). Esta visualización es idónea para observar la inercia del indicador macro e identificar de forma directa las alteraciones en la tendencia causadas por fenómenos coyunturales globales.


Hallazgos Principales:

El IDH promedio de Colombia muestra una trayectoria de crecimiento sostenido pero con una vulnerabilidad latente:

- El indicador inicia el periodo con un valor de **0.667** en 2011 y alcanza su punto máximo de **0.752** en el año 2022.
- La tendencia incremental se ve severamente afectada y estancada en el año **2020**, donde rompe su ritmo de crecimiento debido al impacto socioeconómico de la pandemia, iniciando una lenta recuperación en los años posteriores.

Distribución de IDH por Grupo de IDH

Distribución de IDH por Grupo de IDH



Objetivo:

Esta visualización busca clasificar porcentualmente la composición de la base de datos subnacional de acuerdo con los rangos o categorías internacionales de desarrollo humano en las que se agrupan los territorios colombianos.

Justificación del Gráfico:


Se utiliza un gráfico de torta sectorizado con efecto de extracción (*explode*) y etiquetas porcentuales automáticas. Es un recurso exploratorio que permite entender la proporción estructural de la desigualdad interna, visibilizando qué tan equitativo es el nivel de bienestar entre las distintas regiones de la muestra.

Hallazgos Principales:

La distribución de los datos revela que la gran mayoría de las observaciones de la serie temporal se concentran en las categorías de desarrollo intermedias, mientras que los extremos

(desarrollo muy alto o desarrollo bajo) representan los porcentajes de participación más reducidos del set de datos, evidenciando una fuerte polarización regional.

Promedio Histórico del IDH por Departamento



Objetivo.

Esta gráfica tiene como propósito comparar los promedios generales de desarrollo humano de todos los departamentos de Colombia en el periodo analizado, contrastando directamente frente a los umbrales internacionales del PNUD (IDH Muy Alto, Alto y Bajo).

Justificación del Gráfico:


Se emplea un gráfico de barras horizontales ordenadas de forma descendente con cajas de texto translúcidas de alto contraste para los valores de cada barra. La inclusión de líneas de umbral verticales (`plt.axvline`) de colores sirve como baremo analítico para clasificar visualmente qué territorios logran superar las metas de bienestar y cuáles quedan rezagados en condiciones críticas.

Hallazgos Principales:

- Mientras la capital de la república y los departamentos del centro geográfico superan holgadamente el umbral de IDH Alto (0.700) e incluso rozan el IDH Muy Alto (0.800), existe un grupo marginado al final de la gráfica.

- Los departamentos de Chocó, Guainía, La Guajira, Vaupés y Vichada se sitúan en el extremo inferior, operando de manera persistente cerca o por debajo del umbral de IDH Bajo (0.550), totalmente desconectados de la realidad del resto del país.

Brecha de Desarrollo Humano en Colombia (Top 5 vs. Bottom 5)



Objetivo:

Contrastar de manera directa y dinámica las trayectorias temporales de los dos extremos de la realidad social colombiana: el grupo de los 5 departamentos con mayor desarrollo humano frente al grupo de los 5 departamentos con menor índice del país.


Justificación del Gráfico:

Se utiliza una gráfica doble lineal acoplada con un eje vertical compartido (`sharey=True`) y líneas horizontales de umbral. Compartir el eje Y es metodológicamente indispensable porque permite observar el tamaño real de la brecha de desigualdad: evidencia que el peor departamento del Top 5 está significativamente más arriba que el mejor departamento del Bottom 5, demostrando que no hay convergencia regional a lo largo de los 11 años.

Hallazgos Principales:

- Las trayectorias de los dos bloques se mueven en realidades paralelas: el grupo superior fluctúa sólidamente por encima de los 0.750 y 0.800, mientras que el bloque rezagado se mantiene plano en la franja inferior (entre 0.500 y 0.600).
- Las distancias absolutas entre ambos grupos permanecen prácticamente inalteradas desde 2011 hasta 2022, demostrando que el crecimiento macroeconómico general del país no ha logrado permeare ni corregir el atraso crónico de la periferia.

Promedio Histórico (2011-2022) de las Dimensiones del IDH (Bottom 5):



Objetivo:

Descomponer los índices de los 5 departamentos más rezagados en sus tres dimensiones fundamentales (Esperanza de Vida, Años de Educación e Ingresos) para diagnosticar de forma estadística cuál de ellas es el cuello de botella o la causa raíz de su bajo nivel de desarrollo humano.

Justificación del Gráfico:

Se emplea un gráfico de barras agrupadas por departamento, utilizando las variables normalizadas en la escala uniforme de 0.0 a 1.0. Las líneas discontinuas horizontales con etiquetas de color integradas marcan los promedios específicos de cada dimensión dentro del grupo, permitiendo realizar un diagnóstico sectorial exacto en las regiones críticas.

Hallazgos Principales:

- El Índice de Esperanza de Vida (Salud): Es, por amplio margen, la dimensión mejor posicionada en los 5 departamentos, con barras que superan consistentemente los promedios del grupo.
- El Índice de PIB per Cápita (Ingresos): Muestra un comportamiento variable; en regiones como La Guajira, el indicador es moderadamente alto debido a actividades de explotación económica, pero este flujo monetario se mantiene aislado.
- Los Años Promedio en Educación: Se consolida de forma unánime como el componente más bajo, deficiente y castigado en todos los departamentos del Bottom 5. Es la dimensión que arrastra y deprime el IDH de estas regiones hacia la franja de desarrollo humano bajo.

Posibles Causas:


La exploración inicial de los datos demuestra que las dinámicas económicas regionales no se traducen automáticamente en bienestar social. La dimensión educativa presenta una rigidez estructural crítica en la periferia del país; mientras la salud se mantiene estable gracias

a los mínimos biológicos y la cobertura asistencial, la educación se desploma por fallas masivas en el arraigo y la retención escolar.


Recomendaciones:

Al quedar demostrado estadísticamente que la Dimensión de Educación es el factor detonante del rezago crónico del IDH subnacional en estas regiones, se vuelve estrictamente necesario abandonar la escala macro y pasar a examinar el comportamiento micro de las variables escolares. Por consiguiente, a continuación se desglosan los análisis detallados de las Tasas de Matriculación, Tasas de Deserción y las Curvas de Retención Demográfica de este grupo de departamentos para identificar la raíz de la problemática.

Promedio histórico de las tasas de matriculación de los departamentos rezagados (2011 - 2022)



Promedio histórico de las tasas de deserción de los departamentos rezagados (2011 - 2022)



Objetivo:

Estos gráficos muestran la situación histórica que han vivido los departamentos en los factores educativos que impactan directamente en los años promedio de educación de la población, esto permite observar en qué medida la captación y retención en el sistema educativo se encuentra de cara a la realidad nacional y cual de estos factores es el que más incide en educación.

Justificación del Gráfico:

Se emplea un gráfico de barras tomando como baremo el promedio nacional de cada factor educativo ya que esto permite observar por departamento que tan cerca o lejos se encuentran en términos de mejora con respecto al resto del país. Se decide visualizar las tasas de matriculación y deserción porque permite observar en términos proporcionales cuál factor puede estar causando el mayor impacto.

Hallazgos Principales:

La mayoría de departamentos presentan una tasa matriculación inferior y de deserción muy superior al del promedio nacional, se observa específicamente:

- El promedio de los 5 departamentos muestra una diferencia porcentual de 14% con respecto al promedio nacional ().
- La Guajira es el departamento mejor posicionado del grupo en cuanto a su tasa promedio de matriculación histórica.
- Vaupés es el departamento con menor tasa de matriculación de los 5 departamentos.
- El promedio de los 5 departamentos muestra una diferencia porcentual del 31% con respecto al promedio nacional ().
- La deserción se muestra como el factor educativo de mayor afectación para estas regiones de Colombia el encontrar muy por encima del promedio nacional.

- La Guajira y el Chocó son los únicos departamentos con promedios históricos por debajo del promedio nacional.
- Guainía es el departamento con mayor deserción estudiantil.

Posibles Causas:


- Factores socioeconómicos como la pobreza pueden provocar una mayor deserción en los estudiantes al verse obligados a trabajar para sostener el núcleo familiar o la no poder acceder a los recursos necesarios para continuar la educación (costos de útiles escolares o costos de transporte).
- Factores de infraestructura en las instituciones como ausencia de profesores, acceso a internet o suficientes sedes educativas pueden dificultar la retención de una gran cantidad de estudiantes
- La ausencia de una educación de calidad puede provocar repitencia y eventualmente deserción al estudiante no ser capaz de avanzar en el recorrido académico.

Recomendaciones:

Análisis detallado de las posibles causas de la deserción estudiantil para las regiones rezagadas de Colombia.

- Análisis detallado que permita esclarecer los sectores de la población con mayor tendencia a la deserción para el enfoque de políticas efectivas que la prevengan.
- Refuerzo en las estrategias de subsidio y ayuda material a las poblaciones más proclives a la deserción.
- Priorización de recursos en equipar las instituciones con menor infraestructura que permita una gestión adecuada de grupos de estudiantes y educación de calidad.
- Priorizar el desarrollo de infraestructura que facilite el acceso a Internet a las zonas más vulnerables y a las instituciones educativas.

Evolución de la deserción estudiantil de los departamentos rezagados vs la deserción a nivel nacional (2011 - 2022)



Objetivo:

Este gráfico busca exponer la evolución de la problemática en los años objetivos de la investigación para determinar la longevidad de la problemática, la tendencia general del indicador así como el estado de este indicador para los departamentos objetivo en relación al resto del país.

Justificación del Gráfico:

Se emplea un gráfico de líneas para exponer una evolución a lo largo del tiempo, se opta por agregar franjas paralelas al promedio de los departamentos seleccionados para mostrar el rango completo de oscilación de estos a lo largo del tiempo. Se añade la evolución del promedio nacional para establecer un baremo que permita ver el estado de la deserción en los departamentos rezagados, en comparación con el resto del país.

Hallazgos Principales:

Históricamente el promedio de los departamentos rezagados se ha encontrado muy por encima del promedio nacional, específicamente:

- La deserción ha sido un problema de alto impacto para estas regiones desde al menos 11 años.
- Al igual que el resto de Colombia, los departamentos experimentaron una tendencia a la baja en la deserción la cual se vio interrumpida por el Coronavirus.
- Aunque la tendencia indica una disminución en el tiempo de la deserción, la aceleración de esta disminución dista bastante de la tendencia nacional.


Posibles Causas:

- La falta de supervisión y medición de la deserción o de los factores multidimensionales que la causan pudieron provocar la perpetuación de esta problemática a lo largo del tiempo.
- La evidencia de una progresiva pero insuficiente disminución de la deserción puede implicar que si bien las políticas e iniciativas empleados para atender el problema tiene efecto, los recursos empleados o escala aplicada son insuficientes.
- La contingencia del Coronavirus y su impacto económico y social a nivel regional y mundial probablemente agravó la problemática .

Recomendaciones:

- Análisis detallado de las posibles causas de la deserción estudiantil para las regiones rezagadas de Colombia tomando en cuenta una escala de tiempo por lo menos igual a la contemplada en esta investigación.
- Examen crítico y a profundidad de las políticas aplicadas a lo largo del tiempo para combatir la deserción y evaluar su efectividad y posible continuidad.
- Elaboración de indicadores sólidos que permitan determinar qué políticas son efectivas y cuáles deben ser reconsideradas.

Correlación de la deserción estudiantil y factores estructurales educativos (2011 - 2022)



Objetivo:

Este mapa de calor se plantea establecer los niveles de incidencia que poseen factores relativos a los socioeconómicos (índice de producto interno bruto), infraestructurales (sedes con acceso a internet y tamaño promedio de los grupos) y de calidad educativa (reprobación de los estudiantes) en la deserción de los estudiantes en Colombia.

Justificación del Gráfico:

Se plantea elaborar este mapa de calor con el fin de determinar posibles causas de la deserción en base a los factores estructurales disponibles en el avance del proyecto, esto permite determinar las variables que requieren de mayor investigación así como indicios de cuál debe ser la prioridad en el desarrollo de soluciones a la problemática de la deserción.

Hallazgos Principales:

Se observa que hay una leve correlación en la deserción relacionada a variables socioeconómicas e infraestructurales, específicamente se observa:

- La variable que mayor correlación presenta es el índice de producto interno bruto, esto indica que en efecto existen factores relativos a la situación económica de las familias que inciden en la permanencia del estudiante en el sistema educativo.

- Parece haber una relación positiva entre las sedes con internet y la deserción, no obstante esto no implica necesariamente una causalidad entre mayor acceso a internet y mayor deserción.
- La reprobación tiene una relación positiva con respecto a la deserción, indicando que las variables relativas a la calidad de la relación inciden en la permanencia del estudiante en el sistema educativo.
- La baja correlación en deserción y tamaño de grupo sugiere que el enfoque de la solución no debe situarse en infraestructura más que en economía y calidad educativa.

Limitaciones

- Los datasets empleados solamente contienen datos a nivel marco (departamental) de las variables correlacionadas, para una mayor precisión en las correlaciones se requieren un volumen de datos y una granularidad mayor.
- Debido al alcance y enfoque de la presente investigación factores socioeconómicos, infraestructurales y educativos tales como pobreza a nivel familiar, trabajo infantil, número de sedes, número de profesores, resultados de pruebas icfes no son contemplados. Un análisis exhaustivo que contemple un amplio abanico de variables e indicadores en las áreas anteriormente mencionadas permiten una mayor precisión en la determinación de causas raíces de la deserción estudiantil.



Posibles Causas

- Un bajo índice de producto interno bruto puede ser indicativo de una mayor número de familias en precariedad económica lo que provoca una mayor deserción a hacerle imposible a la familia asumir los gastos de mantener a los hijos en el sistema o implica un coste de oportunidad de cara a permanecer estudiando o iniciar trabajo remunerado.
- La relación entre mayor deserción y mayor presencia de sedes con internet podría deberse a que las iniciativas de los gobiernos en proveer de infraestructura tecnológica están correctamente enfocadas a las poblaciones que más lo necesitan (aquellas con mayor deserción).
- Una baja calidad educativa en las sedes provoca la reprobación de los estudiantes lo que conlleva a la deserción producto de la frustración y un mayor costo en tiempo para avanzar en el trayecto académico exitoso.


Recomendaciones.

- Priorizar las políticas enfocadas en apoyo económico y calidad educativa.
- Enfocar las políticas para solucionar la deserción hacia los recursos materiales de los estudiantes y las familias.
- Desarrollar iniciativas que impulsen una mayor calidad en la educación y evitar la reprobación en estudiantes.
- Mantener los esfuerzos e inversiones en infraestructura sin quitar la prioridad en apoyo económico y calidad educativa.
- Examen crítico y a profundidad que contemple un amplio abanico de variables e indicadores en las áreas anteriormente mencionadas permiten una mayor precisión en la determinación de causas raíces de la deserción estudiantil.


Curva de retención educativa por factores sociodemográficos de los estudiantes en los departamentos rezagados (2011 - 2022)




Retención Educativa por Edad - Género: Masculino




Retención Educativa por Edad - Zona: Rural




Retención Educativa por Edad - Zona: Urbana




Retención Educativa por Edad - Grupo Étnico: Afrodescendiente





Retención Educativa por Edad - Grupo Étnico: Indígenas



Retención Educativa por Edad - Grupo Étnico: Negritudes





Objetivo:

Este gráfico lineal busca determinar la edad promedio en el que los estudiantes tienden a abandonar la educación permitiendo de esta forma determinar la población etaria de mayor vulnerabilidad y que requiere mayor atención. De igual forma esto permite aproximar la brecha de conocimiento que se debe de cubrir en los estudiantes que desertaron en educación.

Justificación del Gráfico

Se emplea un gráfico de líneas para determinar la edad crucial en la que se suele abandonar los estudios en estas regiones. A su vez este gráfico sirve de base para determinar qué poblaciones son aquellas con mayor afectación en cuanto a deserción estudiantil. La curvatura delimitada en este gráfico permite identificar el patrón de deserción en otras categorías sociales como género, zona y grupo étnico.

Hallazgos Principales

La matriculación de estudiantes para la regiones seleccionadas cae significativamente a partir de los 10 años, específicamente se observa:

- La deserción parece empezar a los 10 años de edad, indicando que la mayoría de estudiantes culminan solamente la educación primaria.
- La deserción a los 10 años explica los años promedio de educación de 7 años de estas regiones
- La deserción está causando que la población abandone sus estudios a muy temprana edad impidiendo el acceso a conocimiento importante.
- No hay una mejoría observable en la deserción según el género de los estudiantes, la problemática es generalizada.
- No hay una mejoría observable en la deserción según el grupo étnico de los estudiantes, la problemática es generalizada.
- Se observa una diferencia significativa entre las zonas rurales y urbanas, en donde la problemática está más presente, en las zonas rurales.
- La ausencia de una brecha significativa en cuanto a género y grupo étnico puede sugerir que la problemática tiene como causas raíces factores socio económicos más que culturales.

Limitaciones

- Los datos directamente relacionados con tasas de deserción se dirigen principalmente a categorías territoriales (agrupado por departamento o municipio) hay pocos datos que definen la deserción por grupos demográficos. La presente investigación por eso toma como referencia para estimar la deserción el volumen de matriculación partiendo de la premisa que la matriculación por edad debe bien mantenerse o aumentar en el caso que exista deserción 0 (el mismo estudiante debe ser nuevamente matriculado el siguiente año).
- Se excluyen las tendencias para los grupos étnicos “rom”, “raizales” y “palenquero” por cuanto poseen datos inferiores a diez (10) impidiendo así observar tendencia alguna.

Posibles Causas

- La carencia material de las familias provoca que los estudiantes al alcanzar una edad que les permita realizar trabajos manuales abandonen los estudios para ayudar en el sostenimiento económico del núcleo familiar.
- El aumento de recursos necesarios para continuar la educación media (mayor cantidad de libros, insumos, materiales para prácticas de laboratorio, mayor tiempo para el estudio) crean una barrera para la mayoría de familias que no pueden afrontar los costos
- La falta de suficientes escuelas, docentes o instalaciones en infraestructura (como internet) dificultan a las instituciones retener grandes volúmenes de estudiantes.
- El aumento de la complejidad de los contenidos académicos y una pobre calidad educativa generan una brecha en los estudiantes que les dificultan la transición a la educación media tendiendo a la deserción.

Recomendaciones.

- Focalizar el análisis en las causas de deserción infantil.
- Focalizar esfuerzos en políticas que atiendan factores socioeconómicos.
- Focalización de recursos y políticas en las zonas rurales donde se percibe mayor deserción.
- Refuerzo en las estrategias de subsidio y ayuda material a las poblaciones más proclives a la deserción.
- Priorización de recursos en equipar las instituciones con menor infraestructura que permita una gestión adecuada de grupos de estudiantes y educación de calidad.
- Priorizar el desarrollo de infraestructura que facilite el acceso a Internet a las zonas más vulnerables y a las instituciones educativas.

3. Conclusiones

- **Brechas Territoriales y Rezago en el IDH:** El análisis del comportamiento del Índice de Desarrollo Humano (IDH) a nivel departamental en Colombia durante el periodo 2011-2022 evidencia que, si bien existe una tendencia de mejora a nivel nacional, persisten profundas asimetrías territoriales. Departamentos específicos en regiones periféricas presentan un estancamiento o rezago significativo frente al promedio nacional, lo que demuestra que el crecimiento no se distribuye de manera homogénea y perpetúa ciclos de vulnerabilidad poblacional.
- **Impacto Crítico de la Dimensión Educativa:** Al descomponer estadísticamente el IDH de las regiones con mayor rezago, se concluye que la dimensión de Educación es el factor que mayor impacto negativo genera sobre el indicador global. De manera específica, el rezago en los "Años promedio de educación" indica que el reto principal en estas regiones no radica únicamente en el acceso inicial al sistema escolar, sino en la poca capacidad del sistema para retener a los estudiantes a largo plazo.
- **Correlación con Factores Sociodemográficos:** Se estableció una relación directa entre el rezago en la dimensión educativa y diversas barreras sociodemográficas estructurales. Los departamentos con mayores tasas de deserción y menores años de escolaridad promedio coinciden con aquellos que presentan altos índices de ruralidad, mayor incidencia de pobreza extrema y altos niveles de reprobación académica.
- **Rezago dimensional económico e interdependencia estructural:** El análisis de las dimensiones del IDH revela que la dimensión económica presenta asimismo un rezago crítico y estructural en las regiones periféricas del país, por lo cual se determina que bajo ninguna circunstancia se debe desatender este aspecto en la formulación de políticas de desarrollo. Existe una fuerte evidencia de dependencia cuantitativa entre los bajos ingresos y las deficientes métricas educativas, lo que hace imperativo establecer investigaciones complementarias destinadas a evaluar la incidencia mutua entre ambas dimensiones.

4. Recomendaciones

- **Focalización en factores socioeconómicos y calidad educativa:** El análisis de datos establece que la máxima prioridad debe ser mitigar las vulnerabilidades económicas de

los estudiantes y elevar la calidad pedagógica, manteniendo la inversión en infraestructura sólo como un habilitador secundario. Se recomienda fortalecer programas de bienestar integral, como el Programa de Alimentación Escolar existente (PAE) y los subsidios condicionados, para evitar el abandono escolar temprano. Esta estrategia requiere que el Nivel Nacional garantice el músculo presupuestal, mientras el Nivel Regional ejecuta directamente las intervenciones.

- **Atención territorial basada en estudios estructurales:** Las políticas de desarrollo orientadas a los departamentos rezagados deben abandonar los enfoques genéricos y centralizados. Toda intervención debe fundamentarse en estudios técnicos locales previos que identifiquen con precisión los problemas estructurales específicos de cada zona, tales como la ruralidad dispersa o las dinámicas económicas regionales. Por lo tanto, el Nivel Regional, liderado por las Gobernaciones y sus Secretarías de Planeación, es el ente más adecuado para diagnosticar y ejecutar soluciones adaptadas a la medida de sus realidades sociodemográficas.
- **Registro de datos con mayor granularidad e interseccionalidad:** Para optimizar el monitoreo y la prevención de la deserción escolar, los sistemas de información oficiales deben evolucionar hacia estudios de mayor resolución estadística. Es indispensable incorporar variables sociodemográficas de carácter interseccional, tales como el género, la zona (urbana/rural) y la etnia, superando el sesgo de los promedios departamentales globales. El Nivel Nacional, a través del DANE y el Ministerio de Educación, es el responsable idóneo para estandarizar estas nuevas métricas y permitir la creación de modelos predictivos precisos.
- **Estrategias de retención en transiciones escolares críticas:** Los esfuerzos de cobertura deben transformarse en estrategias de retención, focalizándose intensivamente en las cohortes que atraviesan etapas de transición académica, especialmente el paso a la educación media. Se requiere implementar un acompañamiento pedagógico reforzado y planes de nivelación que eviten que la creciente complejidad curricular detone el abandono del aula. El Nivel Regional, mediante las Secretarías de Educación y las directivas de cada institución oficial, debe ser el encargado de liderar esta reestructuración directamente en el entorno escolar.
- **Estudios de incidencia y diseño de soluciones transversales:** Con el fin de abordar de manera integral los hallazgos expuestos, se recomienda de forma prioritaria la formulación de estudios técnicos específicos orientados a modelar de manera explícita la incidencia e interrelación mutua entre las dimensiones educativa y económica. Estos análisis metodológicos resultan indispensables para diseñar soluciones transversales que impactan simultáneamente ambos frentes, evitando que las intervenciones operen de forma aislada.

5. Limitaciones de la investigación

- **Cobertura Temporal de los Datos:** El estudio abarca de manera rigurosa el período histórico comprendido entre los años 2011 y 2022. En consecuencia, el análisis no captura las variaciones macroeconómicas ni los impactos sociales ocurridos en las vigencias más recientes (2023 en adelante), limitando la visibilidad del panorama en el instante actual.

- **Resolución Espacial y Agregación Departamental:** El alcance del análisis fue llevado a cabo a un nivel de granularidad departamental. Al trabajar con promedios e índices consolidados a gran escala, es estadísticamente probable que se oculten micro-realidades y brechas de desigualdad aún más agudas que ocurren a nivel municipal o veredal dentro de un mismo territorio.
- **Calidad de los Datos y Uso de Imputaciones:** Los conjuntos de datos originales, extraídos de fuentes oficiales, presentaban valores nulos e inconsistencias de formato. Aunque se aplicaron técnicas formales de limpieza e imputación (tales como la interpolación lineal temporal para el tamaño promedio de grupos o el relleno longitudinal para la conectividad a internet), estas técnicas matemáticas asumen tendencias constantes que podrían no reflejar eventos atípicos ocurridos en la realidad local.
- **Multicausalidad No Capturada:** Si bien el análisis logra establecer fuertes correlaciones cuantitativas entre el IDH, la educación y determinantes sociodemográficos, existen múltiples factores cualitativos (tales como fenómenos de orden público, violencia, calidad curricular y entorno familiar) que influyen profundamente en la deserción escolar y el desarrollo humano, los cuales escapan al alcance estrictamente cuantitativo de este ejercicio.

6. Referencias

Ministerio de Educación Nacional de Colombia. (2026). *Estadísticas en educación en preescolar, básica y media por departamento* [Conjunto de datos]. https://www.datos.gov.co/Educaci-n/MEN_ESTADISTICAS_EN_EDUCACION_EN_PREESCOLAR-B-SICA/ji8i-4anb/about_data

Ministerio de Educación Nacional de Colombia. (2026). *Matrícula en educación en preescolar, básica y media* [Conjunto de datos]. https://www.datos.gov.co/Educaci-n/MEN_MATRICULA_EN_EDUCACION_EN_PREESCOLAR-B-SICA-Y/ngw5-c5nw/about_data

Programa de las Naciones Unidas para el Desarrollo. (2024). *Índice de desarrollo humano a nivel departamental en Colombia* [Conjunto de datos]. <https://www.undp.org/es/colombia/data-futures-exchange-platform>

Código empleado

https://colab.research.google.com/drive/1oEPzLqPAaoRs6II_GLFQMTNWAkVtExJ?usp=sharing